

Efecto del PIB y el desempleo sobre el crimen. Un análisis de series de tiempo.

Ricardo Gómez Carrera¹

Angel de Jesús Espinoza Escobar²

Abstract

El objetivo de este trabajo es analizar de manera dinámica el efecto de la actividad económica y el desempleo sobre el crimen (homicidios). Aunque en el pasado ya se ha estudiado la relación entre estas variables; la mayoría de los estudios previos se limitan al análisis del efecto del crimen sobre el PIB. De esta forma, esta investigación contribuye al estudio de la relación inversa para el caso mexicano y con un enfoque de series de tiempo. En la exploración del efecto de la actividad económica y el desempleo sobre el crimen se probaron distintos modelos econométricos tanto condicionales como no condicionales. Mediante la metodología de Davidson y MacKinnon se seleccionó el Modelo Dinámico General parametrizado en diferencias dadas sus propiedades econométricas (capacidad explicativa y dinámica de shocks). Contrario a la relación esperada entre PIB y desempleo sobre homicidios (inversa y positiva respectivamente), nuestro trabajo lleva a conclusiones opuestas. En primer lugar, de nuestros resultados se concluye que ante una aceleración en la actividad económica, no sólo no hay menos criminalidad sino que la cantidad de crímenes (homicidios) aumenta en la misma proporción que aumenta el PIB. Esto lleva a pensar que el crecimiento económico se acompaña de variables que no están siendo consideradas como el crecimiento poblacional o el crecimiento inequitativo del ingreso (que podrían aumentar la criminalidad en sí mismas). En segundo lugar, con nuestro modelo podemos concluir que la desocupación no afecta de manera estructural a la tasa de homicidios, esto es, la gente no mata más por quedarse sin trabajo.

¹Instituto Tecnológico Autónomo de México (ITAM), Ciudad de México, México; E-mail: ricardo.goca90@gmail.com

²Instituto Tecnológico Autónomo de México (ITAM), Ciudad de México, México; E-mail: angel.espinozae@gmail.com

1 Introducción

La criminalidad es uno de los temas que más preocupan a los ciudadanos en el mundo³. Ello se debe a que los efectos negativos del crimen son muy amplios y afectan a la población sin distinción de edad, género o estrato social. Un gran acervo de la literatura ha estudiado el impacto del crimen sobre un muy variado rango de fenómenos. Por mencionar algunos; Cohen (2008), Trellez y Carreras (2012) y Velazquez (2019) encontraron respectivamente efectos negativos del crimen sobre la satisfacción de vida, la participación democrática y diversos resultados laborales. Así, para un país como México en el que las tasas de criminalidad se encuentran en niveles históricos⁴, el estudio del crimen y sus determinantes es particularmente relevante.

El objetivo de este trabajo es analizar de manera dinámica el efecto de la actividad económica y el desempleo sobre el crimen (homicidios) a nivel nacional. Aunque ya se ha estudiado la relación entre el crimen, el desempleo y la actividad económica; es más común encontrar en la literatura análisis de la relación del crimen sobre el PIB⁵. De esta forma, esta investigación contribuye al estudio de la relación inversa (PIB y desempleo sobre crimen) para el caso mexicano y con un enfoque de series de tiempo. Esto es particularmente relevante pues de la literatura existente no es posible obtener resultados generales. La dirección (efectos positivos o negativos) de estas relaciones permanece aún indeterminada, encontrándose muchos estudios que han obtenido resultados opuestos para la misma pregunta⁶.

Intuitivamente se esperaría que la relación entre el PIB y el desempleo sobre homicidios fuera inversa y positiva respectivamente. Una posible explicación causal de lo descrito anteriormente es, por una parte, que un mayor crecimiento económico tiende a aumentar la riqueza y mejorar las posibilidades laborales, elevando con ello el costo de oportunidad de delinquir. A su vez, el desempleo es un indicador también de las perspectivas de empleo en actividades legales de los individuos⁷. Así, el desempleo puede incentivar a los individuos a cometer actos delictivos por la necesidad de obtener recursos de alguna fuente. De esta forma, es de esperarse que a mayor desempleo, se observe un aumento en la criminalidad. Esta hipótesis es consistente con los hallazgos de Edmark (2015) y Ming (2008) para empleo y robos y Neumayer (2003) para actividad económica y homicidios.

³Ipsos-MORI, 2018

⁴Expansión, enero 2019.

⁵Ver Delotto y Otranto (2010), Quiroz (2015), y Ríos (2016)

⁶Cantor y Land (1985)

⁷Cortez e Islas Camargo 2017

Sin embargo, en la literatura se encuentran también resultados que pudieran parecer contraintuitivos. Cantor y Land (1985) encontraron un efecto negativo del desempleo sobre distintos indicadores criminales (mayor desempleo se correlaciona con menos crimen) como homicidios y robo de automóviles. Por su parte, los resultados de Cortez e Islas (2017) parecieran no obedecer la teoría económica, encontrando que a mayor crecimiento económico, la criminalidad aumenta. La justificación de estos hallazgos podría radicar en condiciones muy específicas de las unidades de estudio de estos autores, tales como trampas de pobreza, crecimiento poblacional y crecimiento económico inequitativo.

De esta forma, ante la indeterminación de la literatura existente, realizar el ejercicio para homicidios en el caso mexicano sigue siendo relevante. Determinar relaciones causales entre estas variables puede apoyar en el diseño de políticas públicas para la prevención del crimen y la violencia. Esta investigación es rigurosa en su metodología, la cual parte de la teoría de Wooldridge (2016) y Sabau (2011). Se exploran distintos modelos de comportamiento econométricos de series de tiempo. Mediante la metodología de Davidson y MacKinnon se seleccionó el Modelo Dinámico General parametrizado en diferencias como el más adecuado dadas sus propiedades econométricas. De forma general, los resultados de esta investigación nos llevan a apoyar para el caso mexicano los hallazgos de la segunda corriente de la literatura: un efecto positivo del crecimiento económico sobre el crimen y un efecto negativo del desempleo en el crimen en el corto plazo.

Así, la estructura de este documento de investigación queda como sigue: en la sección dos se describen los datos utilizados, en la sección tres se estiman los distintos modelos de comportamiento, en la sección cuatro se realiza el análisis económico de los resultados y en la sección seis se exponen las conclusiones.

2 Datos

Para este trabajo se utilizaron datos de crimen, PIB y empleo. Para crimen se extrajeron datos mensuales de incidencia delictiva del Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública. Se eligió la variable de homicidios para medir crimen pues su cifra negra no es tan alta como lo es para otros delitos (que no se denuncian)⁸. Además, dado que en 2017 hubo un cambio en la clasificación de los distintos delitos, siguiendo la metodología de Díaz et al (2018) fue necesario reconstruir los datos para 2018 y así ampliar nuestra serie. Para los datos del PIB se usaron las series originales del Producto Interno Bruto trimestral del INEGI. Para los datos de empleo (desocupación) se utilizaron los resultados trimestrales de la ENOE.

Uno de los principales problemas con los datos es que no hay series mensuales para el empleo y actividad económica que también tengan desagregación estatal (el análisis de este trabajo es nacional, no obstante, se consideró este factor de cara a una siguiente línea de investigación

⁸Ethos, 2017

futura). Así, y puesto que la ENOE reporta datos desde 2005, tenemos una muestra con 56 observaciones (nuestros datos van de enero de 2005 a diciembre 2018). Lo anterior hace nuestra muestra pequeña. Esto es también puede ser una restricción para hacer análisis anuales (por la pérdida adicional de información), en cambio nuestras comparaciones son trimestrales. Se optó por hacer un análisis trimestral pese a que tenemos variables de crimen y proxy de desempleo y actividad económica mensuales a nivel nacional. Ello se hizo con el objetivo de abrir la posibilidad a ampliar el análisis a nivel entidad federativa. La extensión natural a nuestro trabajo es realizar distintos análisis con datos trimestrales para cada estado de la República Mexicana y observar si la dinámica es distinta. Esto se justifica dada la evolución heterogénea de la criminalidad en los distintos estados.

3 Estimación del Modelo de Comportamiento

Aunque es posible hacer predicciones de manera sencilla mediante un análisis de modelos incondicionales dinámicos (con modelos como ARMA o ARIMA), dada nuestra pregunta de interés, en la que nos preguntamos el efecto del desempleo y el crecimiento económico sobre la criminalidad, necesitaremos partir de un modelo explicativo. Estos modelos tienen la ventaja de que al pronosticar la variable de interés incorporan información de otras variables relevantes. En esta sección partimos de un modelo explicativo estático que nos servirá de base para estimar diferentes modelos. Contrastaremos entre sí los distintos modelos estimados para obtener el mejor de ellos y que incorpore información del pasado de nuestras series relevantes. Estos últimos ya tomarán en cuenta el comportamiento dinámico de la inercia, los controles y los shocks.

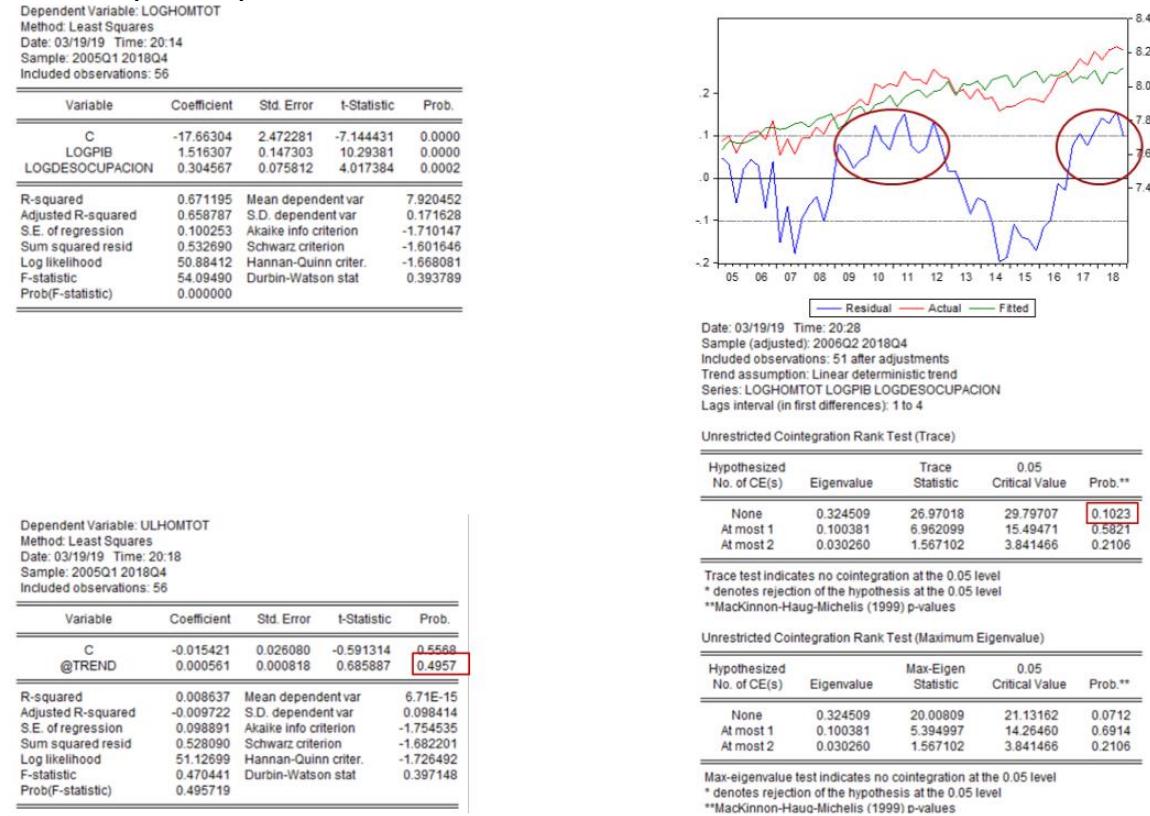
3.1 Modelo explicativo estático

Partimos de un modelo explicativo estático para el que queremos conocer la relación económica entre qué tanto explican el PIB y la desocupación a la tasa de homicidios, como se muestra en la ecuación 1.

$$\log(homtot_t) = \phi + \log(pib_t) + \log(desocupacion_t) + \epsilon_t \quad (1)$$

Independientemente de que el modelo propuesto sea intuitivamente razonable, necesitamos que el modelo cointegre (sea estable). Esto es, que las variables exógenas efectivamente expliquen a la variable endógena. De la Figura 1 observamos que las variables explicativas sí explican de manera significativa en el mismo periodo a la variable explicada. Sin embargo observamos que los residuos parecen no comportarse de manera aleatoria, lo que podría indicar no cointegración. Después de hacer las pruebas de Engle-Granger y Johansen concluimos que el modelo no cointegra (sólo en el sentido de Johansen).

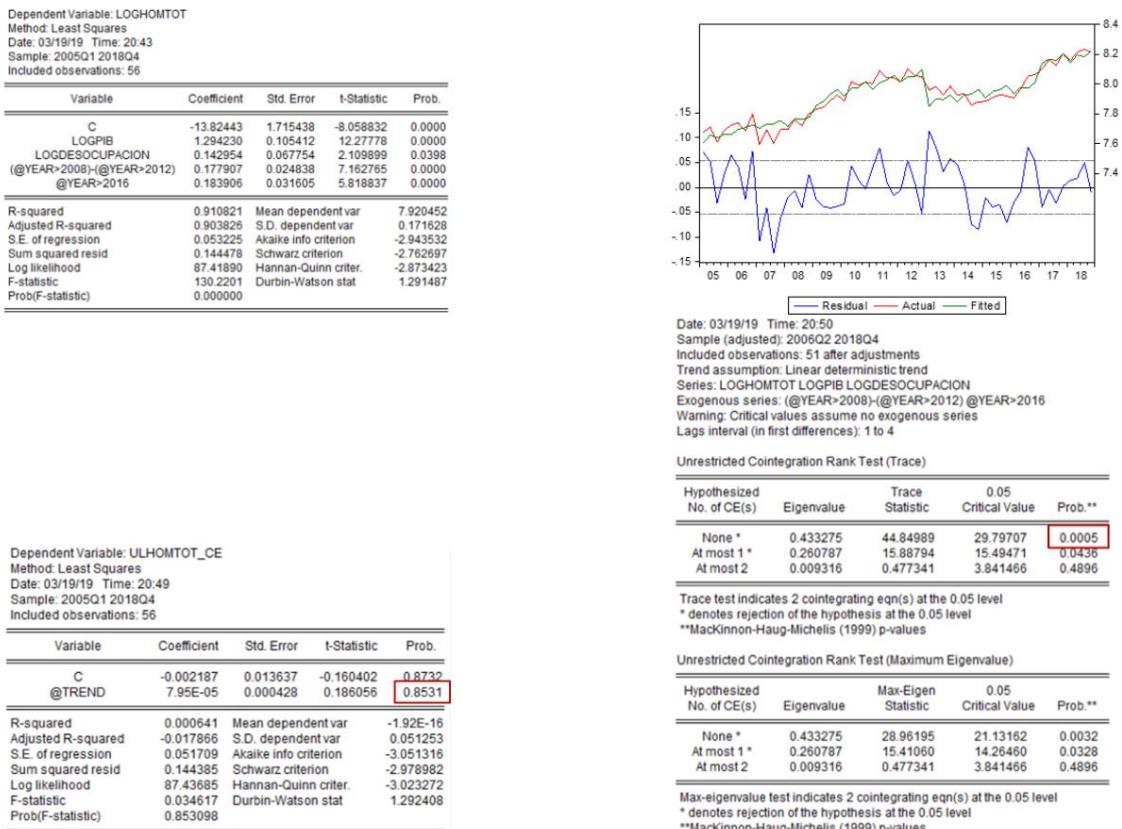
Figura 1: Propuesta de modelo explicativo estático y pruebas Engle-Granger (izquierda) y Johansen (derecha).



Pese a que el modelo inicial propuesto no cointegró, y dado el hecho que nuestro modelo subestima los valores actuales en los períodos de 2009 a 2012 y a partir de 2017, se tienen indicios para creer que hubo un cambio estructural en el comportamiento de la variable estructural. Ello es consistente con la existencia de posturas del gobierno federal más agresivas contra la delincuencia organizada (en particular de 2009 a 2012). Para probar lo anterior, utilizamos la prueba de Chow de cambio estructural. El resultado fue positivo. El modelo estático con cambio estructural de la ecuación 2 se aprecia en la Figura 2, a través de las pruebas de Engle-Granger y de Johansen concluimos que este nuevo modelo con cambio estructural ya cointegra y sus errores tienen un comportamiento más parecido al ruido blanco.

$$\begin{aligned} \log(homtot_t) = & \phi + \log(pib_t) + \log(desocupacion_t) + \delta_1 \mathbb{1}(2008 < año < 2013) \\ & + \delta_2 \mathbb{1}(año < 2015) + \epsilon_t \end{aligned} \quad (2)$$

Figura 2: Modelo explicativo estático con cambio estructural y pruebas de cointegración. Engle-Granger (izquierda) y Johansen (derecha).



Habiendo encontrado un modelo explicativo estático buscamos saber si se cumple el supuesto de exogeneidad para nuestras variables explicativas. Esto es, que las variables exógenas sean efectivamente exógenas y no sean afectadas simultáneamente por la variable endógena. Para ello aplicamos la prueba de Hausman de exogeneidad en la que estimamos instrumentos de las variables explicativas en función de su pasado con el modelo de dos etapas. Luego probamos con la prueba de Hausman (Figura 3) si los instrumentos son significativos y por lo tanto si los debemos de utilizar en lugar de las variables explicativas, aunque de la prueba rechazamos que debamos de utilizar los instrumentos ya que las variables explicativas sí son exógenas (no son significativas).

Figura 3: Modelo estático con cambio estructural. Pruebas de exogeneidad para PIB (izquierda) y desocupación (derecha).

Dependent Variable: LOG(HOMTOT)
Method: Least Squares
Date: 04/11/19 Time: 18:30
Sample (adjusted): 2006Q1 2018Q4
Included observations: 52 after adjustments

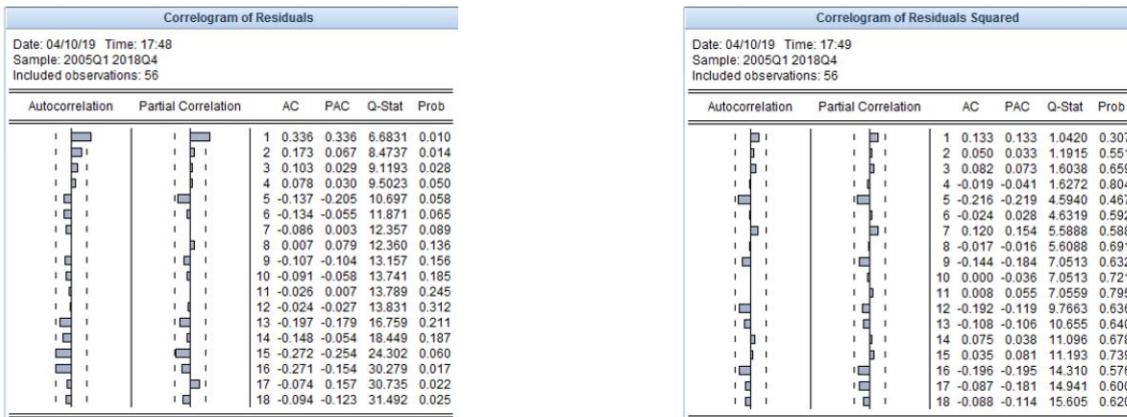
Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	-15.93569	1.967147	-8.050076	0.0000
LOG(PIB)	0.468446	0.591525	0.791929	0.4325
LOG(DESCUPLICACION)	0.133431	0.072361	1.843955	0.0718
(@YEAR>2008)(&@YEAR>2012)	0.191054	0.025771	7.413573	0.0000
@YEAR>2016	0.169772	0.032640	5.201292	0.0000
LOG(PIB_INST)	0.947580	0.610874	1.561189	0.1277
R-squared	0.806331	Mean dependent var	7.930611	
Adjusted R-squared	0.896149	S.D. dependent var	0.162523	
S.E. of regression	0.052374	Akaike info criterion	-2.952630	
Sum squared resid	0.126182	Schwarz criterion	-2.727467	
Log likelihood	82.76838	Hannan-Quinn criter.	-2.866315	
F-statistic	89.01788	Durbin-Watson stat	1.316519	
Prob(F-statistic)	0.000000			

Dependent Variable: LOG(HOMTOT)
Method: Least Squares
Date: 04/11/19 Time: 18:31
Sample (adjusted): 2006Q1 2018Q4
Included observations: 52 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	-15.03734	1.995238	-7.536615	0.0000
LOG(PIB)	1.386155	0.122301	11.16229	0.0000
LOG(DESCUPLICACION)	0.143726	0.181162	0.793359	0.4316
(@YEAR>2008)(&@YEAR>2012)	0.180786	0.027236	6.600307	0.0000
@YEAR>2016	0.183159	0.034131	5.365830	0.0000
LOG(DESCUPLICACION_INST)	0.021896	0.200149	0.109399	0.9134
R-squared	0.901457	Mean dependent var	7.939611	
Adjusted R-squared	0.890745	S.D. dependent var	0.162523	
S.E. of regression	0.053720	Akaike info criterion	-2.901904	
Sum squared resid	0.132747	Schwarz criterion	-2.676760	
Log likelihood	81.44950	Hannan-Quinn criter.	-2.815589	
F-statistic	84.15991	Durbin-Watson stat	1.343628	
Prob(F-statistic)	0.000000			

Por último, revisamos para nuestro modelo explicativo estático, que ya cointegra (es estable) y que ya probamos que cuenta con exogeneidad, si existe autocorrelación y heterocedasticidad. Concluimos de la Figura 4 que sí cuenta con autocorrelación pero no con heterocedasticidad. Por lo tanto, procederemos a calcular los modelos dinámicos para tratar de solucionar la autocorrelación y obtener un mejor modelo econométrico.

Figure 4: Modelo estático con cambio estructural. Pruebas de autocorrelación (izquierda) y heterocedasticidad (derecha).



5.2 Modelos explicativos dinámicos

En primera instancia calculamos un Modelo Dinámico Autorregresivo como se aprecia en la ecuación 3. La desventaja de este modelo es que restringe a que los rezagos de las variables exógenas y de la variable endógena se incluyan únicamente con el mismo periodo rezagado. De la Figura 5 podemos apreciar nuestro modelo MDA(1,0) en el que observamos que hay estabilidad (raíz menor a uno), y no hay autocorrelación ni heterocedasticidad.

$$\begin{aligned}
\log(homtot_t) = \phi + \sum_{j=1}^p \alpha_j \log(homtot_{t-j}) + \sum_{j=0}^p \beta_{1,j} \log(pib_{t-j}) + \sum_{j=0}^p \beta_{2,j} \log(desocupacion_{t-j}) \\
+ \sum_{j=1}^q \theta_j \epsilon_{t-j} + \delta_1 \mathbb{1}(2008 < año < 2013) + \delta_2 \mathbb{1}(año < 2015) + \epsilon_t
\end{aligned} \tag{3}$$

Figura 5: MDA (Modelo Dinámico Auto-Regresivo).

Dependent Variable: LOG(HOMTOT)
 Method: Least Squares
 Date: 05/13/19 Time: 10:18
 Sample (adjusted): 2006Q1 2018Q4
 Included observations: 52 after adjustments
 Convergence achieved after 48 iterations

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	-7.823662	3.231620	-2.420973	0.0195
LOG(PIB)	0.930270	0.196429	4.735901	0.0000
(@YEAR>2008)-(@YEAR>2012)	0.096510	0.034339	2.810507	0.0072
@YEAR>2016	0.135180	0.045621	2.963132	0.0048
LOG(DESOCUPACION(-3))	0.198521	0.071591	2.745033	0.0086
AR(1)	0.755979	0.111876	6.757314	0.0000
R-squared	0.926621	Mean dependent var	7.939611	
Adjusted R-squared	0.918645	S.D. dependent var	0.162523	
S.E. of regression	0.046356	Akaike info criterion	-3.196759	
Sum squared resid	0.098849	Schwarz criterion	-2.971616	
Log likelihood	89.11574	Hannan-Quinn criter.	-3.110444	
F-statistic	116.1760	Durbin-Watson stat	2.138978	
Prob(F-statistic)	0.000000			
Inverted AR Roots	.76			
Correlogram of Residuals				
Date: 05/13/19 Time: 10:19				
Sample: 2006Q1 2018Q4				
Included observations: 52				
Q-statistic probabilities adjusted for 1 ARMA term(s)				
Autocorrelation	Partial Correlation	AC	PAC	Q-Stat
				Prob.
1 -0.084 -0.084 0.3855				
2 0.003 -0.004 0.3860 0.534				
3 0.155 0.158 1.7652 0.414				
4 -0.019 0.007 1.7858 0.618				
5 0.105 0.105 2.4416 0.655				
6 -0.157 -0.171 3.9461 0.557				
7 -0.003 -0.028 3.9465 0.684				
8 -0.038 -0.079 4.0373 0.775				
9 0.043 0.098 4.1599 0.842				
10 -0.085 -0.089 4.6453 0.864				
11 0.032 0.084 4.7157 0.909				
12 -0.070 -0.131 5.0599 0.928				
13 -0.179 -0.160 7.3579 0.833				
14 0.063 -0.020 7.6537 0.865				
15 -0.239 -0.186 11.971 0.609				
16 -0.176 -0.217 14.396 0.496				
17 0.099 0.108 15.175 0.512				
18 0.022 0.111 15.213 0.580				
Correlogram of Residuals Squared				
Date: 05/13/19 Time: 10:20				
Sample: 2006Q1 2018Q4				
Included observations: 52				
Q-statistic probabilities adjusted for 1 ARMA term(s)				
Autocorrelation	Partial Correlation	AC	PAC	Q-Stat
				Prob.
1 -0.073 -0.073 0.2936				
2 0.129 0.125 1.2322 0.267				
3 -0.006 0.012 1.2339 0.540				
4 -0.039 -0.055 1.3213 0.724				
5 0.011 0.004 1.3285 0.857				
6 -0.059 -0.047 1.5428 0.908				
7 0.003 -0.006 1.5433 0.957				
8 0.070 0.084 1.8588 0.967				
9 -0.037 -0.027 1.9499 0.983				
10 -0.049 -0.081 2.1091 0.990				
11 -0.013 -0.012 2.1209 0.995				
12 -0.062 -0.045 2.3906 0.997				
13 -0.007 -0.014 2.3936 0.999				
14 0.000 0.019 2.3937 0.999				
15 -0.045 -0.047 2.5448 1.000				
16 -0.037 -0.066 2.6493 1.000				
17 0.065 0.079 2.9847 1.000				
18 -0.081 -0.059 3.5237 1.000				

Similarmente, estimamos un Modelo Dinámico General (MDG), como el que se aprecia en la ecuación 4. En contraste con el MDA, el MDG permite que los rezagos sean de diferente orden para las variables explicativas y la explicada. En la Figura 6 observamos que nuestro MDG(2,(0,3),2) es estable y no tiene autocorrelación ni heterocedasticidad. Es necesario hacer

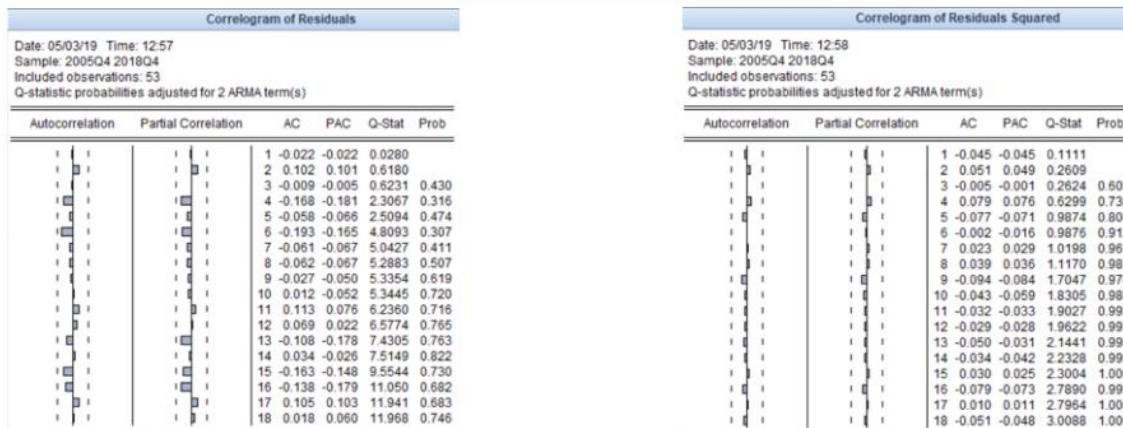
notar que omitimos la variable de desocupación contemporánea debido a su no significancia; ésta es únicamente significativa en su tercer rezago, lo que intuitivamente señala que el desempleo hace 3 trimestres aumenta los homicidios en el presente.

$$\begin{aligned} \log(homtot_t) = \phi + \sum_{j=1}^p \alpha_j \log(homtot_{t-j}) + \sum_{j=0}^r \beta_{1,j} \log(pib_{t-j}) + \sum_{j=0}^s \beta_{2,j} \log(desocupacion_{t-j}) \\ + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \delta_1 \mathbb{1}(2008 < año < 2013) + \delta_2 \mathbb{1}(año < 2015) + \epsilon_t \end{aligned} \quad (4)$$

Figura 6: MDG (Modelo Dinámico General).

Dependent Variable: LOG(HOMTOT)
 Method: Least Squares
 Date: 05/03/19 Time: 12:44
 Sample (adjusted): 2005Q4 2018Q4
 Included observations: 53 after adjustments
 Convergence achieved after 20 iterations
 MA Backcast: 2005Q2 2005Q3

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	-5.222711	2.123264	-2.459756	0.0178
LOG(PIB)	0.560222	0.164327	3.409193	0.0014
(@YEAR>2008)-(@YEAR>2012)	0.102724	0.023855	4.306221	0.0001
@YEAR>2016	0.135945	0.035893	3.787473	0.0004
LOG(HOMTOT(-2))	0.462748	0.114182	4.052704	0.0002
LOG(DESOCUPACION(-3))	0.102485	0.057055	1.796255	0.0792
MA(1)	0.420858	0.153515	2.741482	0.0087
MA(2)	-0.301454	0.162367	-1.856620	0.0699
R-squared	0.944356	Mean dependent var	7.934884	
Adjusted R-squared	0.935700	S.D. dependent var	0.164591	
S.E. of regression	0.041736	Akaike info criterion	-3.376644	
Sum squared resid	0.078386	Schwarz criterion	-3.079241	
Log likelihood	97.48107	Hannan-Quinn criter.	-3.262277	
F-statistic	109.1009	Durbin-Watson stat	2.036013	
Prob(F-statistic)	0.000000			
Inverted MA Roots	.38	-.80		



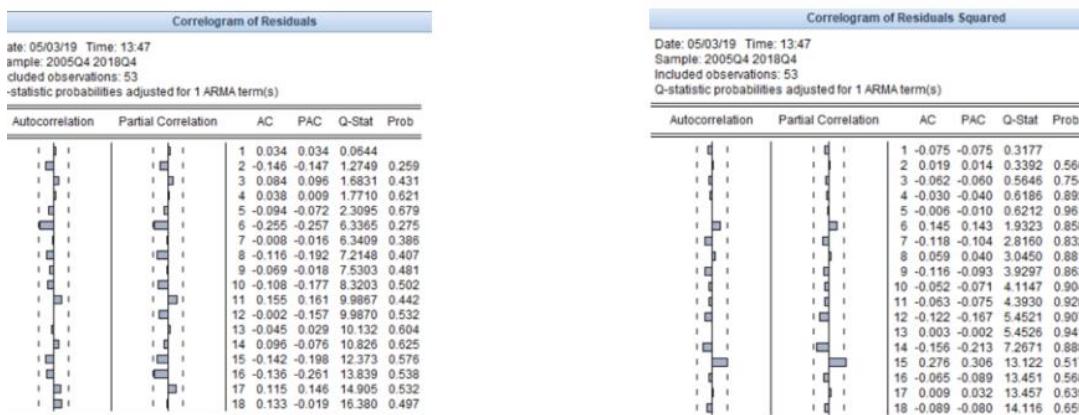
Posteriormente, estimamos un Modelo Dinámico General parametrizado en diferencias (MDGD), como se aprecia en la ecuación 5. Nuestro MDGD(1,(0,2),4) se aprecia en la Figura 7. Como en los anteriores, concluimos que este modelo es estable (el coeficiente de su ancla es menor a 1) e invertible y que no cuenta con autocorrelación ni heterocedasticidad. Como para el MDG, en este caso omitimos desocupación contemporánea debido a su no significancia; desocupación únicamente resultó significativa en su diferencia rezagada en dos periodos. Este es un resultado económico importante ya que lleva a pensar que la desocupación no afecta de manera permanente a la tasa de homicidios.

$$\begin{aligned} \log(homtot_t) = & \phi + \alpha_1 \log(homtot_{t-1}) + \beta_{1,1} \log(pib_t) + \beta_{2,1} \log(desocupacion_t) \\ & + \sum_{j=1}^{p-1} \alpha_j \Delta \log(homtot_{t-j}) + \sum_{j=0}^{r-1} \beta_{1,j} \Delta \log(pib_{t-j}) + \sum_{j=0}^{s-1} \beta_{2,j} \Delta \log(desocupacion_{t-j}) \\ & + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \delta_1 \mathbb{1}(2008 < año < 2013) + \delta_2 \mathbb{1}(año < 2015) + \epsilon_t \end{aligned}$$

Figura 7: MDGD (Modelo Dinámico General parametrizado en diferencias).

Dependent Variable: LOG(HOMTOT)
 Method: Least Squares
 Date: 05/03/19 Time: 13:43
 Sample (adjusted): 2005Q4 2018Q4
 Included observations: 53 after adjustments
 Convergence achieved after 10 iterations
 MA Backcast: 2004Q4 2005Q3

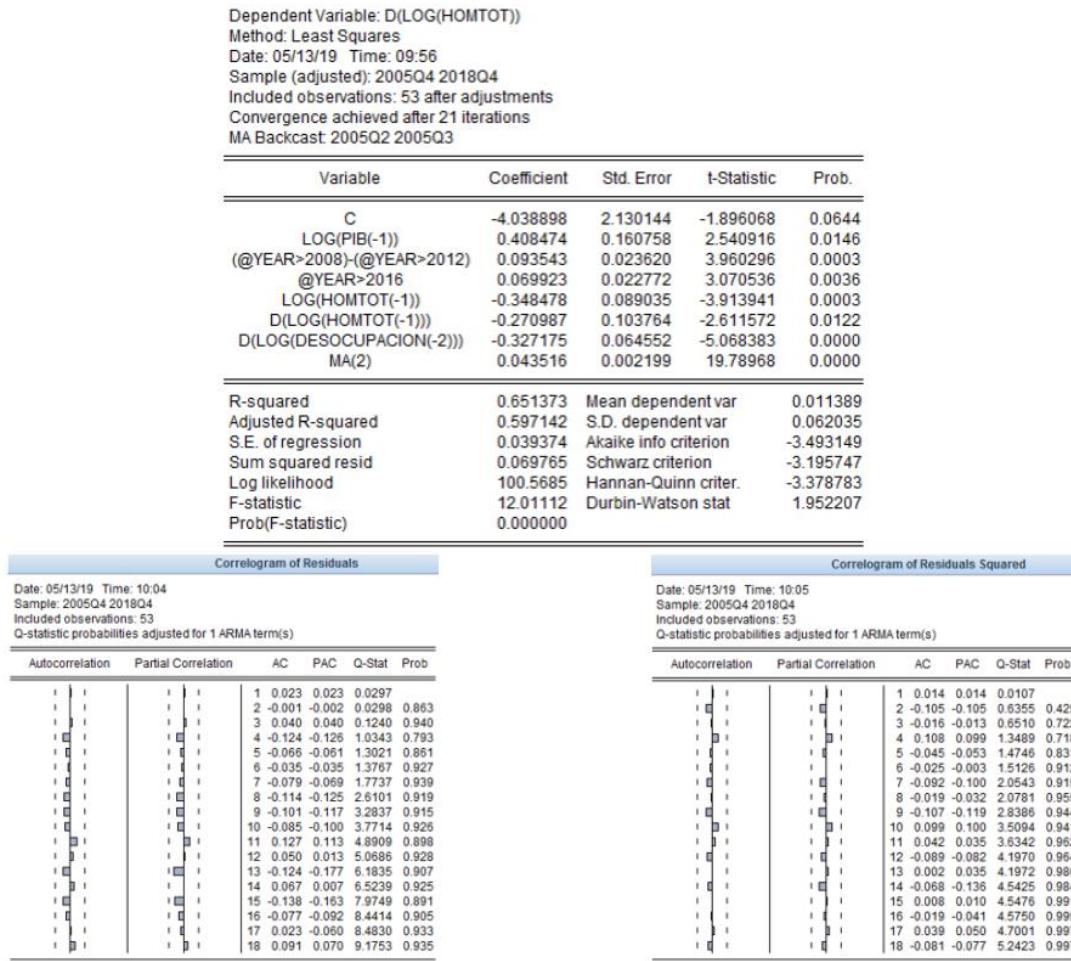
Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	-5.072237	1.700226	-2.983272	0.0046
LOG(PIB)	0.492902	0.131975	3.734825	0.0005
(@YEAR>2008)-(@YEAR>2012)	0.105006	0.018971	5.535116	0.0000
@YEAR>2016	0.081797	0.018088	4.522157	0.0000
LOG(HOMTOT(-1))	0.604136	0.073981	8.166084	0.0000
D(LOG(HOMTOT(-1)))	-0.193667	0.093780	-2.065109	0.0447
D(LOG(DESOCUPACION(-2)))	-0.240198	0.053044	-4.528290	0.0000
MA(4)	-0.328861	0.147777	-2.225392	0.0311
R-squared	0.957037	Mean dependent var	7.934884	
Adjusted R-squared	0.950354	S.D. dependent var	0.164591	
S.E. of regression	0.036673	Akaike info criterion	-3.635293	
Sum squared resid	0.060521	Schwarz criterion	-3.337890	
Log likelihood	104.3353	Hannan-Quinn criter.	-3.520926	
F-statistic	143.2027	Durbin-Watson stat	1.932030	
Prob(F-statistic)	0.000000			
Inverted MA Roots	.76	-.00+.76i	-.00-.76i	-.76



A continuación estimamos un modelo de Mecanismo de Corrección de Errores para buscar que el término de error sea totalmente aleatorio, como se muestra en la ecuación 6. Nuestro MCE(1,(0,2),2) en la Figura 8 de nuevo evidencia estabilidad (ancla menor a cero), no autocorrelación y no heterocedasticidad. Otra vez es importante recalcar que la variable de desocupación únicamente se incluye significativamente como diferencia rezagada en dos trimestres, lo que de nuevo arroja información para concluir que la desocupación no afecta estructuralmente a la tasa de homicidios.

$$\begin{aligned}
\Delta \log(homtot_t) = & \phi + \alpha_1 \log(homtot_{t-1}) + \beta_{1,1} \log(pib_{t-1}) + \beta_{2,1} \log(desocupacion_{t-1}) \\
& + \sum_{j=1}^{p-1} \alpha_j \Delta \log(homtot_{t-j}) + \sum_{j=0}^{r-1} \beta_{1,j} \Delta \log(pib_{t-j}) + \sum_{j=0}^{s-1} \beta_{2,j} \Delta \log(desocupacion_{t-j}) \\
& + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \delta_1 \mathbb{1}(2008 < año < 2013) + \delta_2 \mathbb{1}(año < 2015) + \epsilon_t
\end{aligned} \tag{8}$$

Figura 8: MCE (Mecanismo de Corrección de Errores).



Por último, estimamos un Mecanismo de Corrección de Errores Restringido (MCER) que se muestra en la ecuación 7, con el componente de error impuesto a partir de la ecuación estática

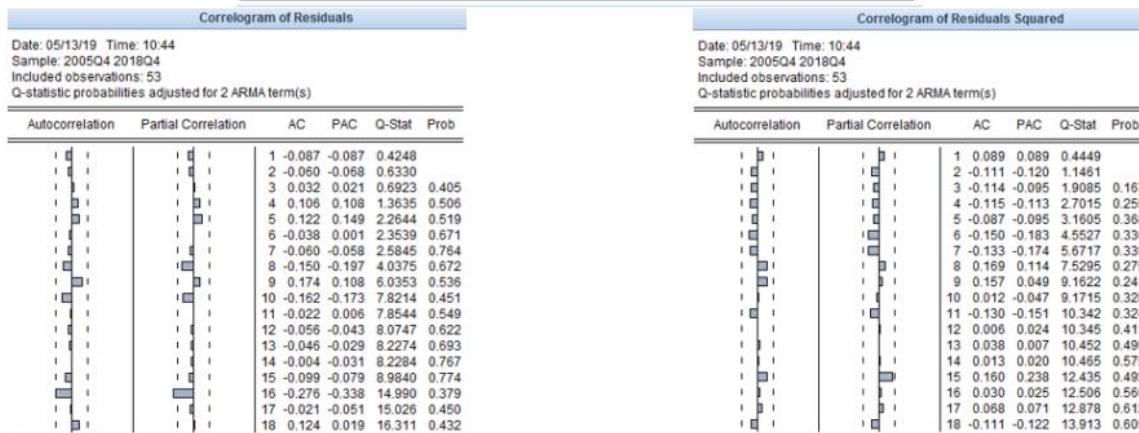
que cointegra (Ecuación 2 y Figura 2). Como se observa en la Figura 9, nuestro MCER(0,(0,1),4) es estable (ancla/residuo menor a cero), y no tiene autocorrelación ni heterocedasticidad. De la misma manera se hace notar que la desocupación únicamente se incluye como diferencia con dos rezagos.

$$\begin{aligned}
 \Delta \log(homtot_t) = & \phi + \hat{u}_{t-1} + \sum_{j=1}^{p-1} \alpha_j \Delta \log(homtot_{t-j}) \\
 & + \sum_{j=0}^{r-1} \beta_{1,j} \Delta \log(pib_{t-j}) + \sum_{j=0}^{s-1} \beta_{2,j} \Delta \log(desocupacion_{t-j}) \\
 & + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \delta_1 \mathbb{1}(2008 < año < 2013) + \delta_2 \mathbb{1}(año < 2015) + \epsilon_t
 \end{aligned} \tag{7}$$

Figura 9: MCER (Mecanismo de Corrección de Errores Restringido, con el componente de error impuesto a partir de la ecuación estática).

Dependent Variable: D(LOG(HOMTOT))
 Method: Least Squares
 Date: 05/16/19 Time: 09:08
 Sample (adjusted): 2005Q4 2018Q4
 Included observations: 53 after adjustments
 Convergence achieved after 12 iterations
 MA Backcast: 2004Q4 2005Q3

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.012808	0.006267	2.043775	0.0466
UMCER(-1)	-0.376798	0.111931	-3.366331	0.0015
D(LOG(PIB(-1)))	-0.545726	0.202364	-2.696757	0.0097
D(LOG(DESOCUPACION(-2)))	-0.227882	0.071222	-3.199586	0.0025
MA(2)	0.230052	0.091572	2.512242	0.0155
MA(4)	-0.174985	0.091569	-1.910971	0.0621
R-squared	0.583420	Mean dependent var	0.011389	
Adjusted R-squared	0.539103	S.D. dependent var	0.062035	
S.E. of regression	0.042115	Akaike info criterion	-3.390546	
Sum squared resid	0.083363	Schwarz criterion	-3.167494	
Log likelihood	95.84947	Hannan-Quinn criter.	-3.304771	
F-statistic	13.16472	Durbin-Watson stat	2.213999	
Prob(F-statistic)	0.000000			
Inverted MA Roots	.56	.00-.74i		



Una vez que estimamos nuestros cinco modelos explicativos dinámicos, buscamos escoger el mejor modelo. Para esto utilizamos la metodología de Davidson y MacKinnon para saber cuanto estima cada modelo de lo que deja de explicar el otro y así compararlos. De los estadísticos t (calculados al estimar los pronósticos estáticos par el mismo periodo de cada modelo e incluir ese pronóstico estático en los otros cuatro modelos) en la Figura 10 podemos concluir que el modelo que explica más de lo que dejan de explicar los otros modelos es el MDGD para casi todos los casos y los otros modelos no explican tan bien al MDGD. Por lo tanto el MDGD es el mejor modelo para analizar el comportamiento dinámico de los homicidios en función del PIB y la desocupación.

Figura 10: Metodología de Davidson y MacKinnon para selección de mejor modelo.
Qué tanto explican los otros modelos

Modelo estimado	MDA	MDG	MDGD	MCE	MCER
	C1	C2	C3	C4	C5
Last updated: 05/16/19 - 09:40					
MDA	R1	0.000000	4.642248	7.650709	5.629220
MDG	R2	1.665695	0.000000	6.101979	3.283768
MDGD	R3	0.224092	0.742397	0.000000	0.790369
MCE	R4	2.002593	1.672180	4.438709	0.000000
MCER	R5	2.516941	6.247546	3.997949	2.169448
					0.462804
					0.000000

6 Análisis Económico

Habiendo seleccionado nuestro mejor modelo estadístico para explicar la tasa de homicidios en función del PIB y de la tasa de desocupación procedemos a realizar análisis económico. Por medio de la dinámica comparada podemos saber cómo afectan los shocks y cambios en las variables explicativas a la tasa de homicidios en el corto y mediano plazo. Como el MDGD resultó ser el mejor modelo estadístico realizaremos la dinámica comparada para este modelo. De la Figura 11 podemos apreciar al analizar los shocks y los multiplicadores aislados que se trata de un buen modelo estadístico dado que los multiplicadores de shocks y aislados tienden a cero en el corto plazo. Esto se interpreta como que un choque transitorio exógeno o de las variables explicativas sólo perdura en el corto plazo. En el caso del PIB, un aumento transitorio afecta positivamente a las tasas de homicidios pero el efecto se diluye en el corto plazo. En el caso de desocupación un aumento transitorio tiene un impacto negativo e inmediato en las tasas de homicidios pero inmediatamente después el impacto es positivo y perdura muy poco tiempo. Para el caso de un shock externo, éste impacta positivamente en el muy corto plazo y posteriormente negativamente pero desaparece.

De la Figura 11 también analizamos los multiplicadores acumulados y estos presentan un comportamiento muy interesante. En el mediano plazo la tasa del PIB y de homicidios tiene una relación positiva y casi 1 a 1. Esto implica que la tasa de homicidios aumentará en el mediano plazo casi en la misma proporción que aumente el ingreso. Una posible explicación es que el PIB esté funcionando como proxy de población entonces a mayor población habrá mayores homicidios. Una explicación alterna podría ser que el crecimiento económico viene acompañado de una mayor persistencia de la desigualdad.

Otra conclusión a partir de la dinámica comparada es que en el mediano plazo la tasa de desocupación no afecta la tasa de homicidios, esto lleva a pensar que la desocupación tiene un efecto transitorio y no uno estructural en la tasa de homicidios. Lo que también es interesante es

que la tasa de desocupación afecta inversamente a la tasa de homicidios, aunque solo en el corto plazo; esto es totalmente contraintuitivo ya que lleva a pensar que a mayor desempleo habrá menos homicidios.

Por último, de la Figura 12 que incluye pronósticos a 2025 de todos los modelos dinámicos y de manera específica al mejor modelo seleccionado (MDGD), podemos concluir que el MDG, el MCE y el MDGD pronostican valores muy similares de homicidios. En particular con el pronóstico de MDGD podemos esperar que *caeteris paribus* haya alrededor de 4,000 homicidios al cuatrimestre para finales de 2025.

Figura 11: Dinámica comparativa para el mejor modelo. Multiplicadores de shocks (izquierda), multiplicadores aislados (centro) y multiplicadores acumulados (derecha).

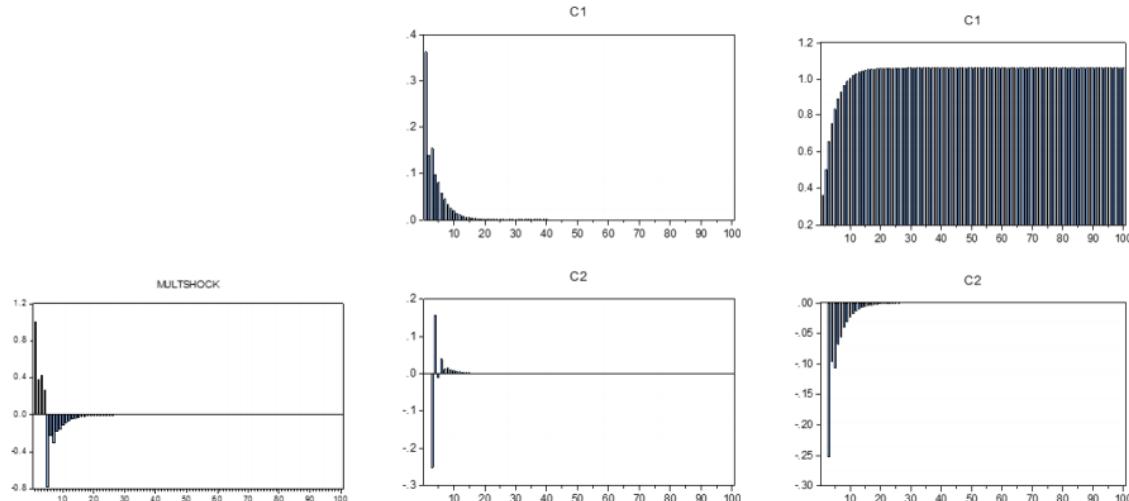
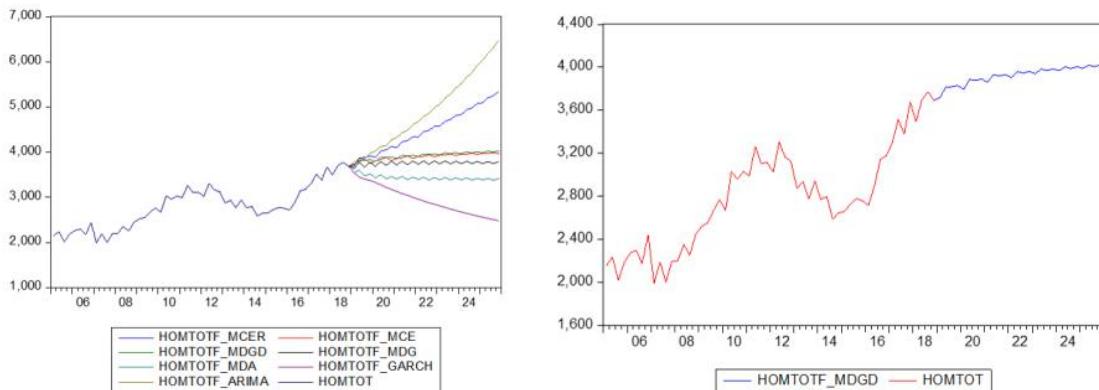


Figura 12: Pronóstico de homicidios totales. Todos los modelos (izquierda) y mejor modelo (derecha).



7 Conclusiones

A partir de la inclusión de dinámica de la inercia, de los controles y de los shocks hemos podido estimar buenos modelos económicos para explicar a la tasa de homicidios nacional en función del PIB nacional y la desocupación nacional, de entre los que destaca el Modelo Dinámico General parametrizado en diferencias, el cual seleccionamos como mejor modelo. Nuestro modelo tiene características económicas deseables como estabilidad, invertibilidad, exogeneidad, no autocorrelación y no heterocedasticidad.

A pesar de sus buenas características económicas, existen elementos del modelo que limitan su alcance debido al sesgo que no logramos eliminar. El primero es el hecho de que la muestra sea tan reducida (56 observaciones) lo que hace que nuestro análisis contenga relativamente poca información. No obstante, pese a ello, hemos logrado obtener modelos con significancia estadística, ello podría hablarnos de la fuerte correlación que existe entre nuestras variables de estudio. Aunque lo deseable sería contar con un modelo con al menos 100 observaciones, la muestra actual nos permite ampliar el alcance de este estudio para hacer comparaciones desagregando a nivel estatal. La segunda fuente de posibles sesgos es que a pesar de que la variable homicidios totales nos permite contar con una proxy de criminalidad precisa debido a que todos los homicidios se reportan, existe el sesgo de que no todos los homicidios son crímenes, ya que esta variable está contabilizando tanto homicidios dolosos como culposos. Una extensión adicional a este análisis es una selección distinta de nuestra variable explicativa, esto podría ser al tomar robo como la variable explicativa (la pregunta es además interesante, al existir la posibilidad de que otros delitos tengan dinámicas distintas).

Una vez habiendo dicho lo anterior, de nuestro modelo podemos obtener varias conclusiones económicas que refutan las hipótesis que se creerían como más intuitivas. La primera hipótesis

de ellas es que a mayor ingreso del país (PIB) habría menor criminalidad, pero por medio de nuestro modelo podemos concluir que no sólo no hay menos criminalidad sino que la cantidad de crímenes (homicidios) aumenta en la misma proporción que aumenta el PIB. Esto lleva a pensar que la variable PIB podría funcionar como variables proxy que no están siendo consideradas y abren la posibilidad a nuevos análisis y reflexiones profundas. Por ejemplo, crecimiento poblacional o crecimiento inequitativo del ingreso. De esta manera ya tendría mayor sentido intuitivo que a mayor PIB haya mayores homicidios. La segunda hipótesis que tuvimos fue que a mayor desempleo (desocupación) habría mayor criminalidad, esto hace sentido intuitivo ya que a falta de una fuente de ingresos la gente podría recurrir a la criminalidad. Sin embargo, con nuestro modelo podemos concluir que la desocupación no afecta de manera estructural a la tasa de homicidios, esto es, la gente no mata más por quedarse sin trabajo. Lo que es todavía más interesante es que el efecto de la desocupación es inverso en el corto plazo, a mayor desocupación habrá menos homicidios; esto llama la atención debido a que es un efecto contraintuitivo.

Los resultados de este modelo podrían llevar a pensar que a pesar de ser un buen modelo econométrico, las variables escogidas como endógena (homicidios) y exógenas (PIB y desocupación) podrían contener sesgos lo que haga que no podamos aislar el efecto del ingreso y el desempleo sobre los niveles de criminalidad. No obstante, aunque pudiera parecer que nuestros hallazgos son poco comunes y contradicen la teoría económica, en la literatura se encuentran estudios que han llegado a conclusiones similares (Cortez e Islas (2017), Chiricos (1987) y Cantor y Land (1985), por ejemplo).

Como extensión futura del modelo, buscamos replicar esta metodología a nivel estatal para explotar esa desagregación y tomar además distintas variables endógenas, como es el caso de robos o lesiones. Esperamos contrastar el comportamiento del PIB y la desocupación sobre la criminalidad en distintas entidades federativas para obtener conclusiones a niveles locales donde podamos concluir con mayor precisión.

Referencias

- Cantor, D. and K. C. Land (1985). Unemployment and crime rates in the post-world war ii united states: A theoretical and empirical analysis. *American Sociological Review*, 317–332.
- Chicoma, J. L. (2018). Descifrando el gasto en seguridad. *Ethos Laboratorio de Políticas Públicas*.
- Cohen, M. (2008). The effect of crime on life satisfaction. *The Journal of Legal Studies*@(S2), S325–S353.
- Cortez, W. W., A. Islas-Camargo, et al. (2017). Delincuencia, pobreza y crecimiento económico en México, ¿existe una relación asimétrica? *Delinquency, poverty and economic growth in Mexico, is there an asymmetric relationship?*. Technical report, University Library of Munich, Germany.
- Detotto, C. and E. Otranto (2010). Does crime affect economic growth? *International Review for Social Sciences*.
- Díaz, e. a. (2018). La consolidación de los registros y estadísticas delictivas en México.
- Edmark, K. (2005). Unemployment and crime: Is there a connection? *Scandinavian Journal of Economics*@(2), 353–373.
- Expansión (2018). México toca récord de homicidios en 2018.
- Lin, M.-J. (2008). Does unemployment increase crime? evidence from us data 1974–2000. *Journal of Human resources*@(2), 413–436.
- MORI, I. The Rise and Fall of Public Concern about Crime, 2011, <https://www.ipsos.com/ipsos-mori/en-uk/rise-and-fall-public-concern-about-crime>, revisado 2019-05-12.
- Neumayer, E. (2003). Good policy can lower violent crime: Evidence from a cross-national panel of homicide rates, 1980–97. *Journal of Peace Research*@(6), 619–640.
- Sabau García, H. (2011). Análisis econométrico dinámico: una exploración para series de tiempo con el método econométrico. Universidad Iberoamericana.
- T Cantor, D. and K. L. C. (1985). Unemployment and crime rates in the postworld war II united states: a theoretical and empirical analysis. *America Sociological Review*.
- Trelles, A. and M. Carreras (2012). Bullets and votes: Violence and electoral participation in México. *Journal of Politics in Latin America*@(2), 89–123.

Velásquez, A. (2019). The economic burden of crime: Evidence from México. *Journal of Human Resources*, 0716–8072r2.

Wooldridge, J. M. (2016). *Introductory econometrics: A modern approach*. Nelson Education.